

세렌디피티 향상을 위한 LLM 활용 다면적 추천 시스템

Multi-Faceted LLM Recommendation System for Enhancing Serendipity


국민대학교 비즈니스IT전문대학원

석사과정 이기주

다양한 선택을 제한하는 필터 버블

필터버블(Filter Bubbles)

- 알고리즘이 사용자의 과거 행동 기반 정보 선별
- 자신의 관점을 강화하는 정보만 접함
- 개인화 알고리즘 → 유사 콘텐츠 반복 노출
- 인지적 편향 강화
- 선택의 자율성 제한
- 새로운 탐색 기회(Serendipity) 상실



정확도 기반 학습으로 심화되는 필터버블

추천시스템에서의 필터버블

- 과거 상호작용 데이터 기반 정확도(Accuracy) 최적화
 - 사용자가 클릭/구매한 아이템과 유사한 패턴 학습
 - 의미적으로 관련 있는 다른 카테고리는 낮은 점수
-
- 과거 패턴 반복 → 모델 학습 편향 → 유사 패턴 추천 강화
 - 좁은 범위의 높은 정확도, 다양성 감소 초래
 - 사용자의 잠재적 관심사 탐색 불가



다양성 확보 시도와 정확도의 감소

전통적 Diversification 접근의 한계

- MMR, DPP와 같은 필터 버블 해결하기 위한 접근 방식 등장
- 이미 선택된 아이템과 유사도가 낮은 아이템을 추가 선택
- 임베딩 간 유사도를 측정하여 서로 다른 아이템들을 선택

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

$$\mathcal{Y} \sim \text{DPP}(\mathbf{K}) \iff p(A \subseteq \mathcal{Y}) = \det(K_A) \text{ for all } A \subseteq \Omega.$$

높은 정확도

- 유사 아이템 추천
- 과거 선호 패턴 중심

높은 다양성

- 이질적 아이템 추천
- 새로운 영역 탐색

다양성 감소

상충 관계

정확도 감소

다양성 확보 시 정확도 감소, 아이템간 의미적 관계 고려 X

→ 의미적으로 관련있는 다양한 아이템 추천의 어려움


필터버블 완화를 위한 평가지표

필터버블 완화를 평가하는 지표 연구 등장


- 다양성을 평가하기 위한 새로운 성능 평가 지표 등장
 - 사용자의 잠재적 관심사 발견 능력을 측정하는 다양성 평가 지표 필요
- *Coverage* : 추천 시스템이 실제로 추천한 아이템의 비율로 다양성 평가
 - *ILD*(Intra-List Distance) : 추천된 아이템 간의 거리로 다양성 평가

High-Diversity 데이터셋 (CCDF, 2024)

- 사용자의 과거 상호작용 이력에 포함되지 않은 새로운 카테고리의 아이템을 추천하는 정도
- 사용자가 구매한 적 없는 새로운 카테고리 영역 탐색 목표
- 마지막 구매 아이템의 카테고리 and 사용자 이력 아이템의 카테고리가 다른 샘플로 평가




새로운 패러다임: LLM 기반 추천시스템



LLM 기반 추천시스템


- 텍스트 기반 의미적 이해 가능한 LLM을 활용
- 컨텍스트 추론 능력을 활용하여 문맥 기반 추천 가능
- 자연어 기반 제어를 통해 유연한 태스크 수행 가능



- LLM의 의미적 이해 능력을 활용한 새로운 추천 접근
- Cold-Start 문제에도 강력해 다양한 연구 진행 중


LLM 기반 추천: Two-stage 파이프라인

LlamaRec (2023) - 전통적 모델과 LLM의 결합



Stage 1

- 전통적 추천 모델을 통해 후보를 생성
- LLM 대비 효율적인 계산으로 전체 아이템에서 후보를 압축





Stage 2

- LLM을 활용하여 후보 아이템의 추천 순위 재정렬 수행
- 프롬프트로 이력과 후보를 입력받아 후보 간의 최종적인 순위 생성

LLM기반 추천: 임베딩 주입 기법

LLARA (2024) - 전통적 모델의 학습 패턴 전이



- 전통적 추천 모델의 임베딩을 LLM에 직접 주입하여 지식 전이
- 협업 필터링의 학습된 상호작용 패턴을 직접적으로 활용
- 전통적 추천 모델의 패턴 이해 능력과 LLM의 의미 이해 능력을 동시에 활용

LLM기반 추천으로 필터버블을 완화하기 위한 전략

LlamaRec

- Two-Stage 파이프라인 구조
- 전통적 모델로 효율적 후보 생성
- LLM으로 의미 기반 리랭킹



- Stage 1 에서 다양한 카테고리 후보 확보
- 카테고리 선호도 기반 후보 생성
- 다양한 카테고리 커버리지 확보

LLaRA

- 임베딩 주입 기법
- 전통적 모델의 패턴 지식 활용
- 협업 필터링 + LLM 추론 결합




- 카테고리 레벨의 패턴 지식을 활용
- 아이템과 카테고리의 임베딩을 LLM에 주입
- 다면적 임베딩으로 사용자의 잠재적 선호도 반영

LLM기반 추천으로 필터버블을 완화하기 위한 전략

**카테고리 선호도 기반 후보 생성 + 다면적 임베딩 기반 재순위화로
사용자의 잠재적 선호도를 반영한 추천을 통해 필터 버블 완화**



제안 방법론



Phase 1


- 카테고리별 상품 선호도를 고려한 추천 아이템 후보군을 구성
- 각 추천 모델에서 생성한 임베딩 정보를 LLM이 이해할 수 있는 구조로 변환

Phase 2

- 다면적 임베딩을 아이템명 및 카테고리명과 함께 프롬프트에 통합
- LLM에 입력해 후보 인덱스의 확률을 버벌라이저로 처리하여 최종 추천을 수행

Phase 1:아이템 / 카테고리 후보 검색

- 사용자의 구매 이력을 타임스탬프 기준으로 순차적 정렬
- 인덱스를 활용하여 아이템/카테고리 시퀀스를 구성





Item Title	Learning Resources Attribute Apples	UNO Flash Game	Small World Toys Little Handyman Tool Box	Webkinz Lion	Toysmith Mighty Magnet Set
Item Index	4967	1893	901	720	1332
Category	Mathematics & Counting	Card Games	Pretend Play	Electronic Pets	Pretend Play
Category Index	10202	10504	10901	11004	10901
Timestamp	1555781542	1556040742	1556386342	1556645542	1557250342

Item Sequence: [4967, 1893, 901, 720, 1332]

Category Sequence: [10202, 10504, 10901, 11004, 10901]

Phase 1:아이템 / 카테고리 후보 검색

- 아이템 시퀀스를 아이템 추천 모델에 입력하여 사용자 아이템 임베딩 생성
- 사용자 아이템 임베딩과 모든 후보 아이템의 임베딩간 유사도를 비교하여 아이템 점수 도출
- 카테고리 점수는 카테고리 시퀀스/추천 모델을 활용하여 도출





제안 방법론

Phase 1: 후보아이템 선정





- 사전에 설정한 추천 다양성 정도 k 값을 입력
- k 값으로 후보 카테고리 개수 선정하여 상위 k 개의 후보 카테고리 선정
- 각 후보 카테고리에서 추천 점수가 높은 아이템 n 개를 최종 후보로 선정
- 각 카테고리마다 n 개의 아이템이 후보로 선정되어 최종 $k \times n$ 개의 후보가 선정됨




Phase 1: 다면적 임베딩 변환

- 다면적 임베딩은 아이템 정보와 카테고리 정보를 담은 두 임베딩 벡터를 의미
- 최종 후보 아이템의 아이템 임베딩과 카테고리 임베딩을 LLM 프롬프트에 주입
- 프로젝터를 활용하여 LLM이 이해 가능한 차원의 임베딩으로 변환
- 프로젝터는 순차적 추천 모델의 정보를 LLM이 이해할 수 있도록 학습



Phase 2: 최종 프롬프트 구성

- 최종 프롬프트는 지시문, 사용자 구매이력, 최종 후보+다면적 임베딩, 질문으로 구성
- 구매이력과 후보의 아이템은 [아이템명-카테고리명]으로 구성



You are a recommendation system.
Given user history in chronological order,
recommend an item from the candidate pool with its index letter.



Instruction

This user's purchase history:
1. Learning Resources Attribute - Mathematics & Counting,
2. UNO Flash Game - Card Games,
...



User History
(Item - Category)



Item candidates:
(A) Magnetic Tiles [ItemEmb] - Pretend Play [CateEmb]
(B) Magnetic Building Set [ItemEmb] - Pretend Play [CateEmb]
...
Next item:




Candidates
& Question

Phase 2: 최종 후보 재순위화

- LLM 리랭커에 최종 프롬프트를 입력하여 후보에 대한 재순위화 수행
- 리랭커에 입력된 프롬프트는 트랜스포머 계층을 거쳐 로짓 값으로 변환
- 버벌라이저에 로짓 값을 입력하여 최종 추천 점수 도출



실험



Accuracy-based Recommendation Model

- LRURec (LLM X)
- LlamaRec (LLM O)

Diversity-based Recommendation Model

- DGRec (LLM X)
- IDSR (LLM X)

Proposed Model

실험 개요

추천 후보 선정 방식

- 추천 카테고리 k값: 10개
- 카테고리별 추천 아이템 수 n값: 2개
- 최종 후보 수: 20개

LLM 하이퍼파라미터

- Batch Size: 4
- Learning Rate: 0.0001
- Optimizer: AdamW
- Epoch: 2
- 아이템명 길이 최대 길이: 2048
- 최대 시퀀스 길이: 10
- LoRA R: 8
- LoRA Alpha: 32

LRURec 하이퍼파라미터

- Batch Size: 64
- Learning Rate: 0.001
- Optimizer: AdamW
- Epoch: 500 (Early Stop)

실험 개요

데이터셋 선정

- Amazon Review Dataset (Toys & Games) 데이터셋 사용
- 5개 이상의 아이템을 구매한 사용자, 5번 이상 구매한 아이템 사용
- 카테고리 인덱스는 3-Depth를 기준으로 직접 생성

Item Title	Eeboo Animal Bingo
Category	Toys
Category Index	1



1

Item Title	Crocodile Dentist
Category	Toys - Games
Category Index	1 05



105

Item Title	Webkinz Lion
Category	Toys - Puzzles - 3-D Puzzles
Category Index	1 01 02



10102

Category Index

평가/검증/학습데이터셋구성

- 평가 / 검증 / 학습 데이터는 Leave-One-Out 방식으로 구성
- 총 n 개의 사용자 이력이 있을 때, $[1, \dots, n-1], [n]$ 으로 평가 데이터 구성
- $[1, \dots, n-2], [n-1]$ 로 검증 데이터 구성
- $[1, \dots, n-3], [n-2]$ 로 학습 데이터 구성

(a) Test Data Organization
(Category)

[10102, 10504, 101, 1, 10102, 103]
 Test Input Sample Test Label

(b) Validation Data Organization
(Category)

[10102, 10504, 101, 1, 10102, 103]
 Val. Input Sample Val. Label

(c) Train Data Organization
(Category)

[10102, 10504, 101, 1, 10102, 103]
 Train Input Sample Train Label

High-Diversity 평가데이터 구성

- **High-Diversity** 평가 데이터: Test Label의 카테고리가 Test Sequence에 없는 카테고리인 데이터 샘플

Num.	Test Input (Category)	Test Label (Category)	N-Diversity Data
1	10102, 10504, 101, 1, 10102	103	O
2	104, 11002, 103, 11002, 1, 10301	1	
3	109, 10807, 10807, 10604, 109, 10401	10604	
4	10705, 10309, 107, 1, 10202, 103	10401	O
...			

성능평가 척도

Recall - Metrics

- 실제 관련 아이템 중 상위 k개 추천에서 발견된 비율
- $\text{Recall}@k = |\text{추천된 } k\text{개 아이템} \cap \text{실제 관련 아이템}| / |\text{실제 관련 아이템}|$

정답 포함 여부 측정 (순위 무관)

NDCG - Metrics

- 순서를 고려한 정확도 지표
- $\text{IDCG}@k$ = 이상적인 순서로 배열했을 때의 DCG 값
- $\text{DCG}@k = \sum_{i=1}^k \frac{(2^{\text{rel}_i} - 1)}{\log^2(i + 1)}$ • $\text{NDCG}_n = \frac{\text{DCG}_n}{\text{IDCG}_n}$

정답 순위의 상대적 중요도 평가

MRR - Metrics

- 첫 번째 관련 아이템의 순위의 역수의 평균
- $\text{RR} = 1 / \text{Label의 추천 순위}$
- $\text{MRR} = \frac{1}{|U|} \times \sum_{u=1}^{|U|} \text{RR}_u$

성능평가척도

추론 결과 예시

[User 315]

- 최종 후보 : [8519, 8013, 1927, 8045, 8923, 3022, 3340, 6630, 3262, 8491, 7933, 8424, 2324, 8856, 1129, 8240, **8182**, 7125, 7211, 7945]
- 리랭킹 결과 : [8519, **8182**, 8013, 7125, 3262, 7211, 8240, 6630, 1129, 8491, 7945, 3022, 8923, 3340, 8424, 7933, 8045, 2324, 1927, 8856]


정답 인덱스: 8182

후보 내 위치: 17

리랭킹 후 위치: 2

High-Diversity 평가 데이터 성능 비교

- 모든 지표에서 최고 성능
- Recall@10 기준 2위 LlamaRec 대비 84% 향상
- 필터 버블 완화 능력 입증




Metric	k	LRURec	LlamaRec	DGRec	IDSR	Proposed Method
Recall@k	5	0.0251	<u>0.0264</u>	0.0016	0.0236	0.0304
	10	0.0354	<u>0.0380</u>	0.0034	0.0300	0.0552
NDCG@k	5	0.0183	<u>0.0191</u>	0.0008	0.0183	0.0223
	10	0.0215	<u>0.0229</u>	0.0014	0.0204	0.0303
MRR@k	5	0.0160	<u>0.0167</u>	0.0006	0.0166	0.0196
	10	0.0173	<u>0.0183</u>	0.0008	0.0175	0.0229

- Users = 10,746
- Items = 8,868
- Categories = 179

전체 평가 데이터 성능 비교

- Diversity-based Model 대비 3배 이상 정확도
- Accuracy-based Model과 비교 가능한 수준
- 정확도-다양성 균형 달성



Metric	k	LRURec	LlamaRec	DGRec	IDSR	Proposed Method
Recall@k	5	<u>0.0720</u>	0.0758	0.0044	0.0222	0.0500
	10	<u>0.0907</u>	0.0969	0.0070	0.0278	0.0900
NDCG@k	5	<u>0.0543</u>	0.0569	0.0027	0.0166	0.0308
	10	<u>0.0603</u>	0.0638	0.0035	0.0184	0.0436
MRR@k	5	<u>0.0485</u>	0.0507	0.0021	0.0148	0.0246
	10	<u>0.0509</u>	0.0536	0.0025	0.0155	0.0298

- Users = 18,023
- Items = 9,004
- Categories = 179

결론

기여

- 학술적 기여
 - 아이템 & 카테고리 임베딩을 동시에 활용한 다면적 임베딩 통합 방법론 제안
 - 표면적 다양성을 넘어 사용자 잠재 선호도를 반영한 의미 있는 다양성 제공
- 실무적 기여
 - 사용자 경험 개선 및 새로운 탐색 기회 제공

한계 및 연구 방향

- 카테고리 기반 후보 추출과 다면적 임베딩 사이의 개별 기여도 검증 필요
- 다양한 도메인 및 언어 환경 내에서 검증하여 일반화 가능성 확인 필요

감사합니다

Q&A

이 기 주

M | 010-2759-9469

E | kijoo0714@kookmin.ac.kr